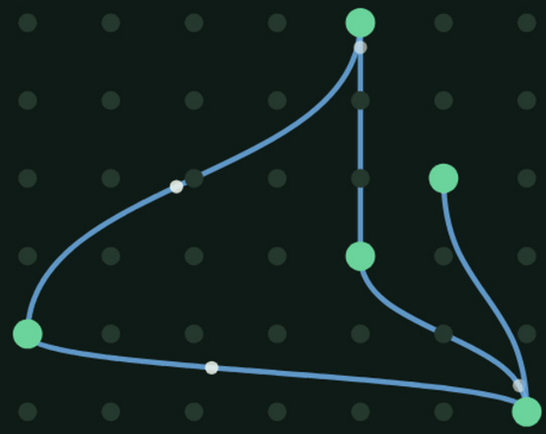
TALLER · PARTE 2 DE 2

Dentro del modelo

Una introducción a la interpretabilidad mecanicista

Rubén Fernández Boullón · Universidade de Vigo



LA MOTIVACIÓN

Sabemos entrenar estos modelos, no sabemos qué aprenden



Seguridad

Detectar comportamientos indeseados, como engaño o sesgos, mirando dentro y no solo las respuestas.



Confianza

Desplegar IA en entornos de alto riesgo, como la salud, exige saber *por qué* decide lo que decide.



Ciencia

Una red entrenada es un algoritmo que nadie escribió. Queremos leerlo.

DOS PREGUNTAS DISTINTAS

De «qué miró» a «cómo lo calculó»

Atribución de entradas

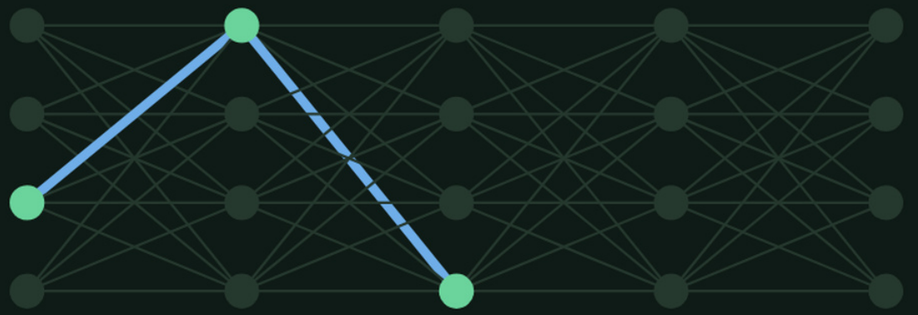
¿Qué partes de la entrada influyeron en la salida?

`The` `movie` `was` `not` `bad` `at` `all`

SHAP, LIME, mapas de saliencia. Útil, pero no dice qué hace el modelo con esa información.

Interpretabilidad mecanicista

¿Qué algoritmo implementa la red, y en qué piezas?

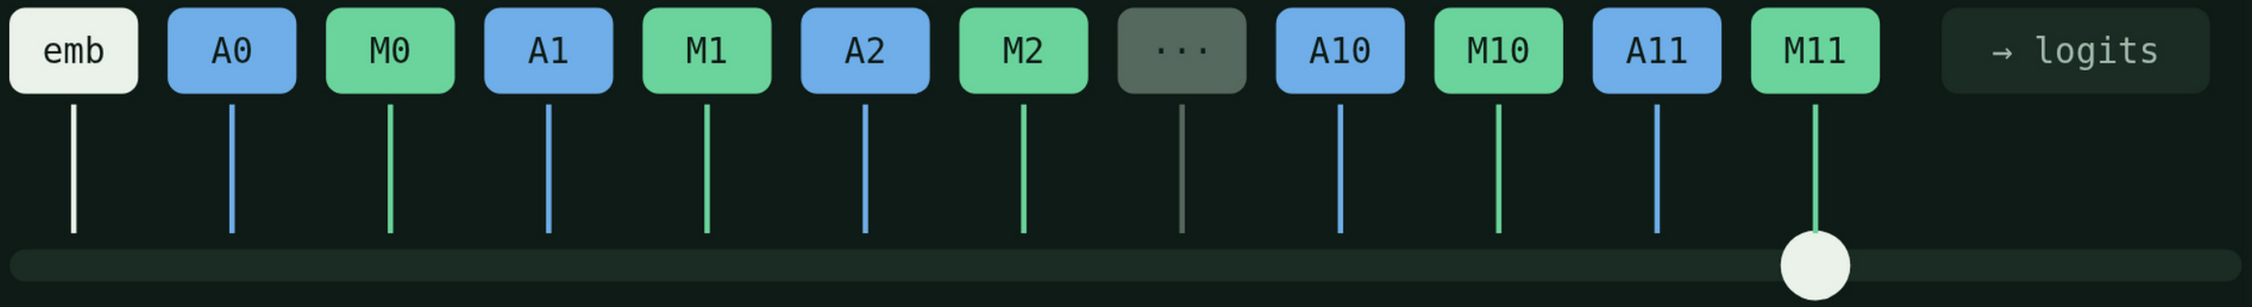


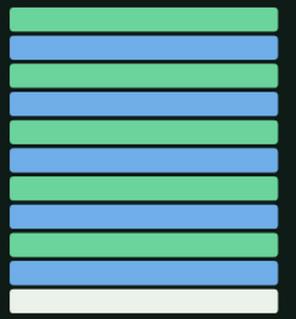
Ingeniería inversa: tenemos el binario, los pesos, y queremos el código fuente.

Atribución ilustrativa sobre una frase de ejemplo

CONCEPTO 1 · EL RESIDUAL STREAM

Un canal compartido donde todas las capas leen y escriben





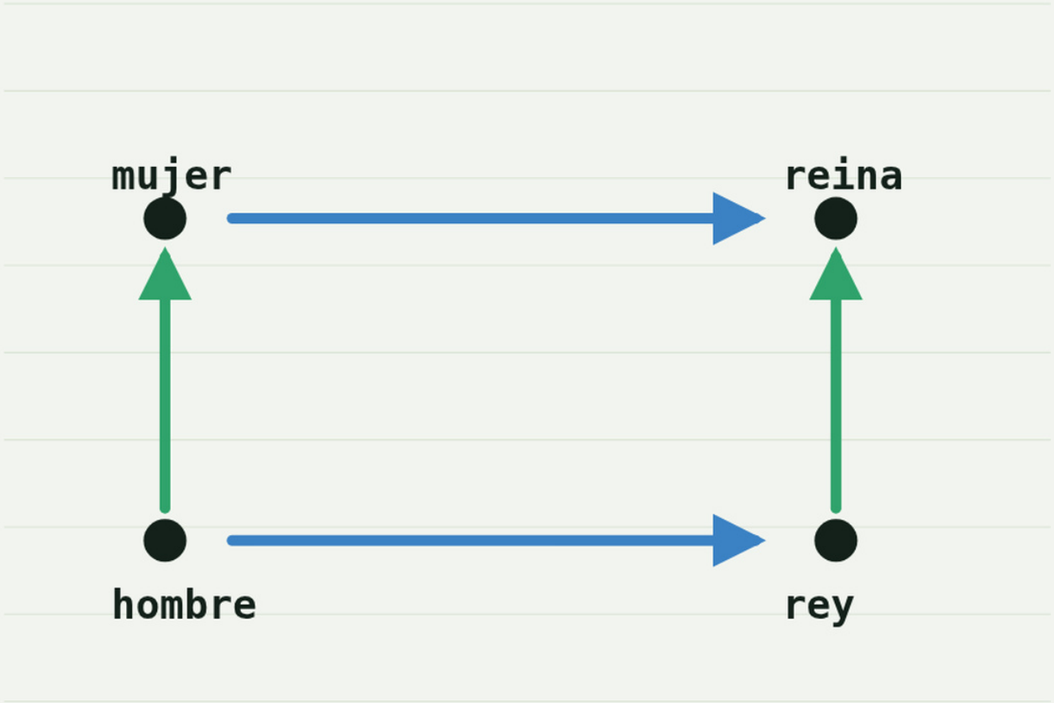
```
x_final = embedding + Σ salidas de atención + Σ salidas de MLP
```

Comprobado en el notebook 2: reconstruir el residual final sumando todas las piezas da un **error de 0,0**.

A = salida de atención de una capa, M = salida de MLP. Marco de Elhage et al. (2021), *A Mathematical Framework for Transformer Circuits*

CONCEPTO 2 · FEATURES COMO DIRECCIONES

Los conceptos viven en direcciones del espacio



Mismo desplazamiento hombre → mujer y rey → reina: una dirección de «género»

Otra dirección, ortogonal: «realeza»

Una activación ≈ suma de features × intensidad

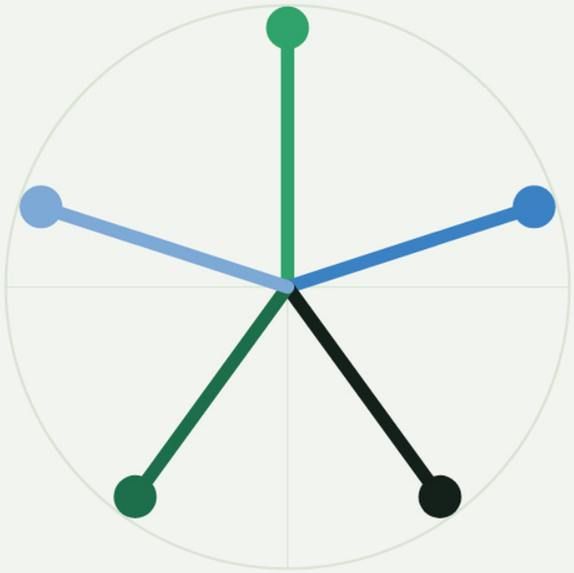
```
a ≈ 0,9·realeza + 0,8·femenino + …
```

Ilustración clásica de embeddings de palabras. Hipótesis de representación lineal

CONCEPTO 3 · SUPERPOSICIÓN

Más conceptos que dimensiones

Features escasas: caben las 5



casi ortogonales, con interferencia

Cuando las features son **escasas** (casi nunca se activan a la vez), el modelo puede meter 5 en 2 dimensiones con un poco de interferencia.

Consecuencia: una neurona no corresponde a un concepto. Es **polisemántica**.

```
neurona hipotética #42 se activa con:
```

código Python recetas de cocina

Según Elhage et al. (2022), *Toy Models of Superposition*. La neurona del ejemplo es ilustrativa

LA CAJA DE HERRAMIENTAS

Cinco herramientas, de mirar a intervenir

Observar

`run_with_cache`

¿Qué valores toma cada pieza?

Leer

`logit lens`

¿Qué predice cada capa intermedia?

Romper

`ablación`

Si apago esta pieza, ¿qué falla?

Trasplantar

`patching`

¿Dónde está la información que decide?

Empujar

`steering`

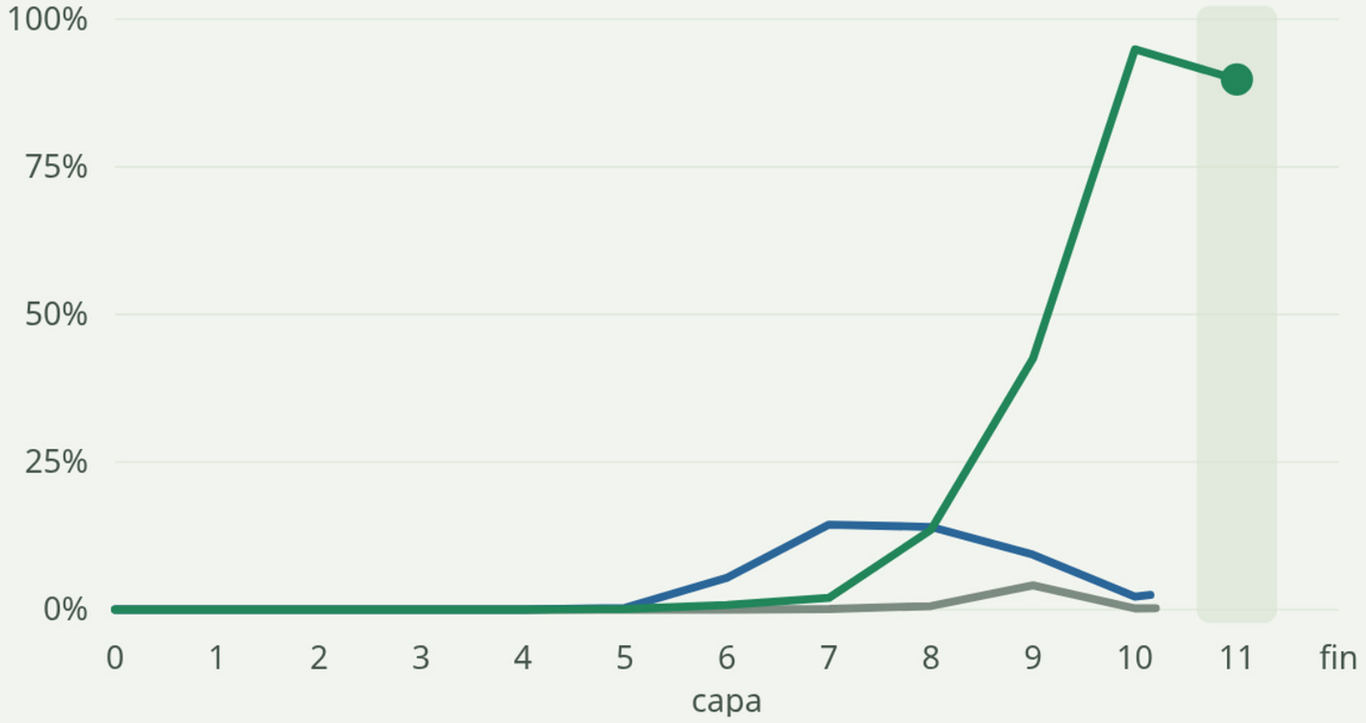
¿Puedo cambiar su conducta?

correlación — causalidad

HERRAMIENTA · LOGIT LENS

¿En qué capa «sabe» la respuesta?

Prompt: **“Michael Jordan plays the sport of”**



tras la capa 11

top-1 si el modelo acabara aquí:

basketball

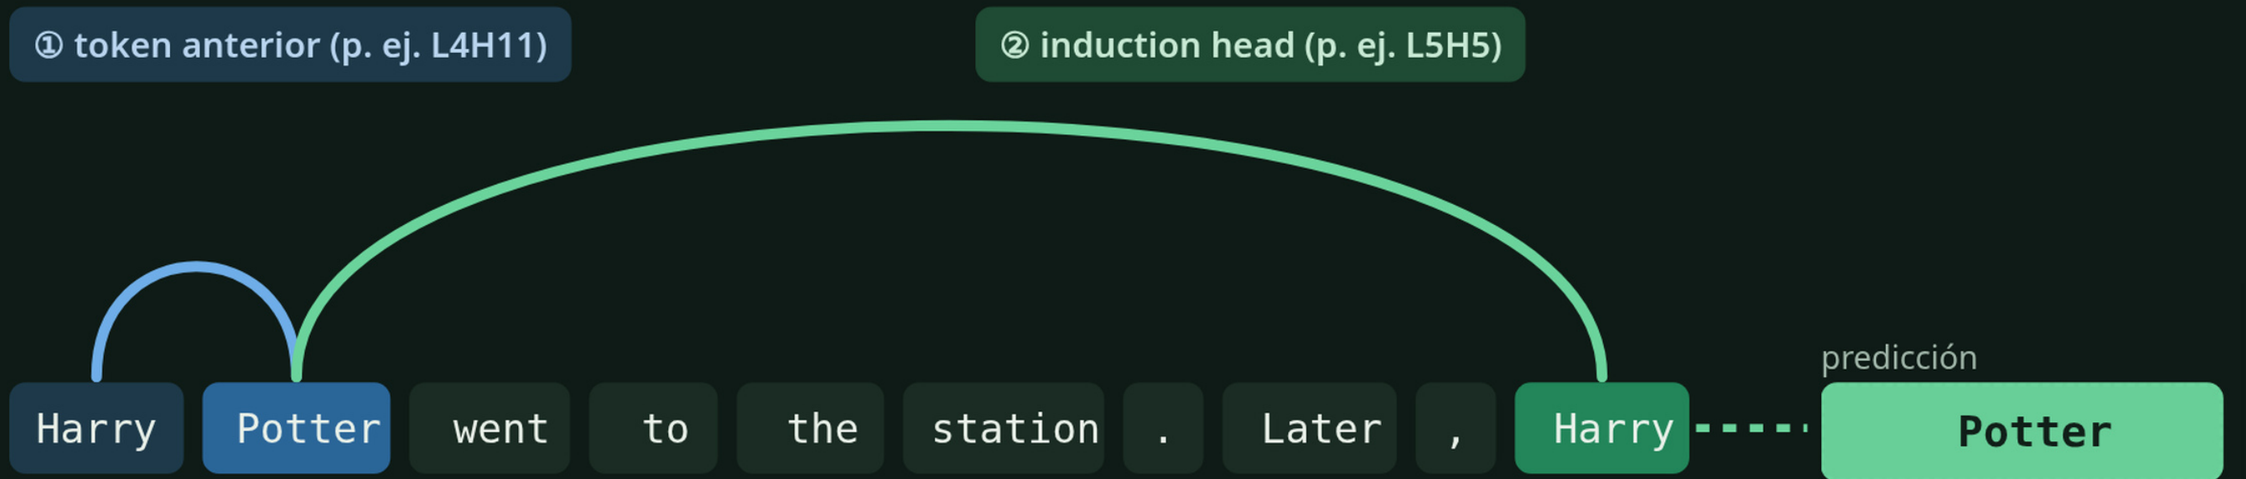
P(basketball) = 89.8%

- basketball
- football
- golf

GPT-2 small, valores reales del notebook 2. Capa 0 = embeddings; «fin» = salida del modelo

CIRCUITO 1 · INDUCTION HEADS

Dos cabezas que colaboran para copiar



1 Una cabeza de **token anterior** escribe en « Potter»: «vengo detrás de Harry».

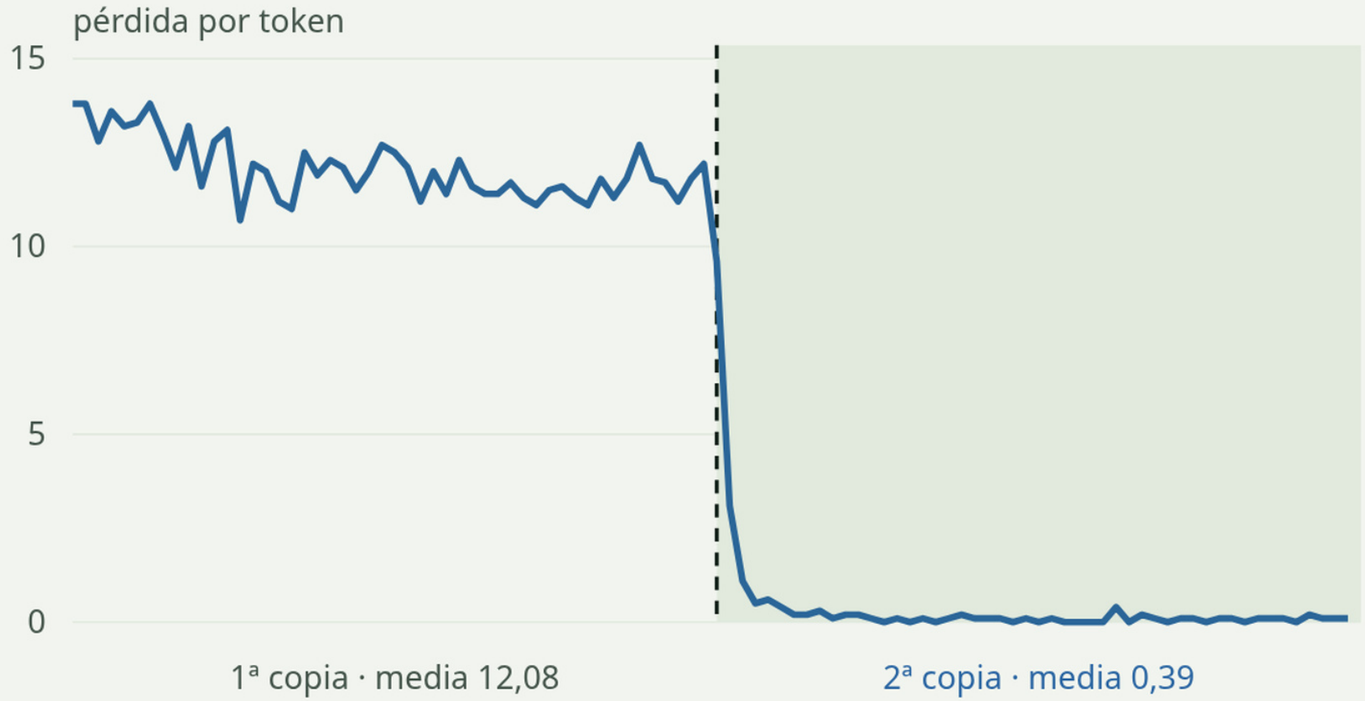
2 La **induction head**, desde el segundo «Harry», busca al que venía detrás de Harry.

3 Lo encuentra en « Potter» y **copia** ese token como predicción.

Patrón A B … A → B. Olsson et al. (2022), *In-context Learning and Induction Heads*

CIRCUITO 1 · ENCONTRARLAS EN GPT-2

Tokens aleatorios repetidos: la segunda vez es trivial

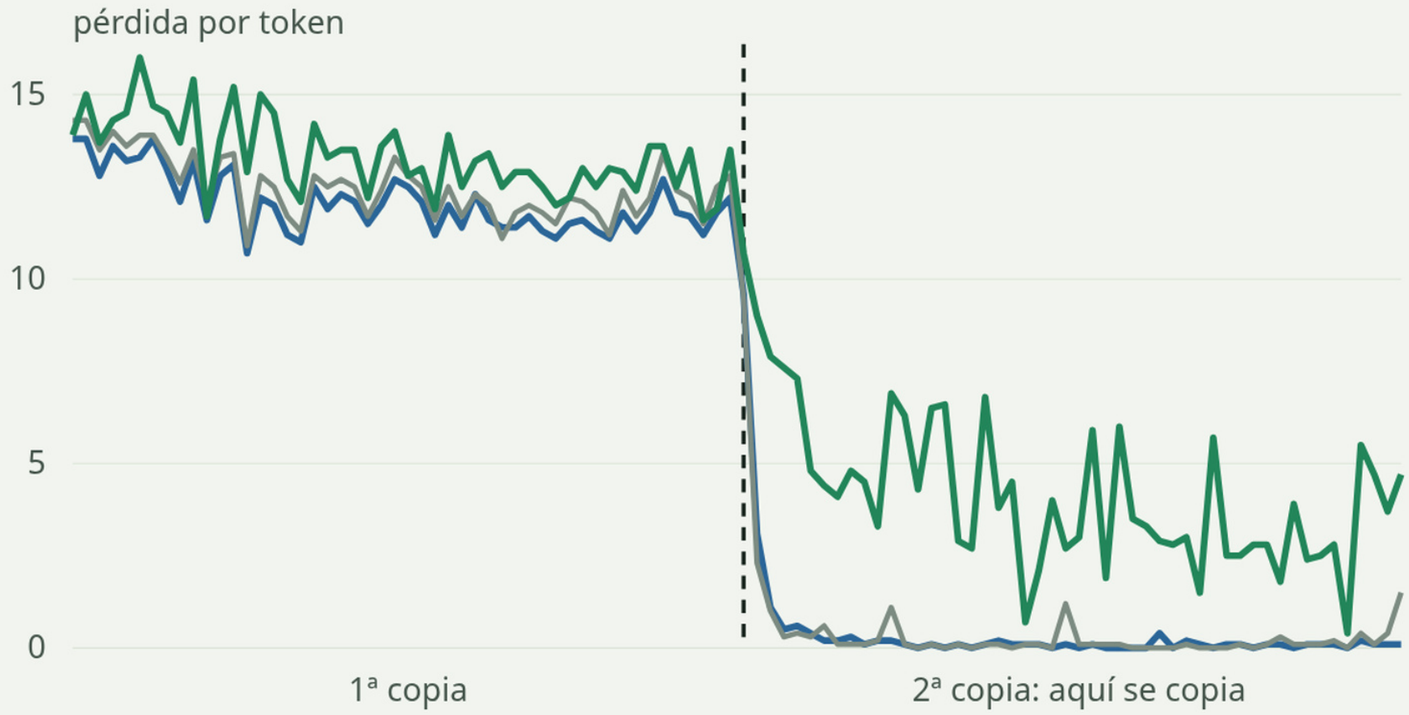




GPT-2 small, 8 secuencias de 50 tokens aleatorios repetidas dos veces. Datos reales del notebook 2

HERRAMIENTA · ABLACIÓN

Ver un patrón no prueba nada: hay que romper



Modelo original

0,39

6 cabezas al azar apagadas

0,43

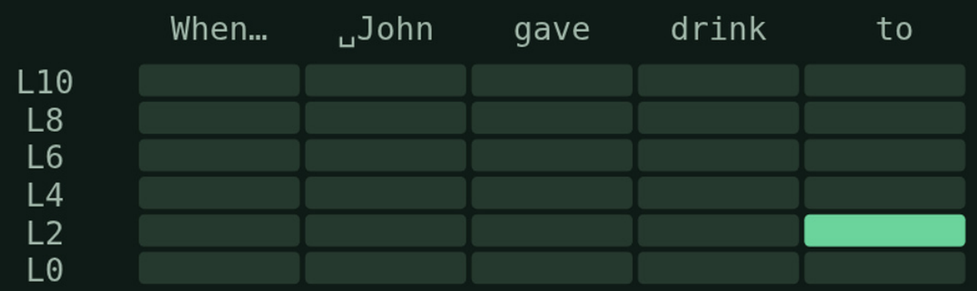
6 induction heads apagadas

4,23

Pérdida media en la 2ª copia, GPT-2 small. Ablación = poner a cero la salida de la cabeza (hook_z). Datos reales

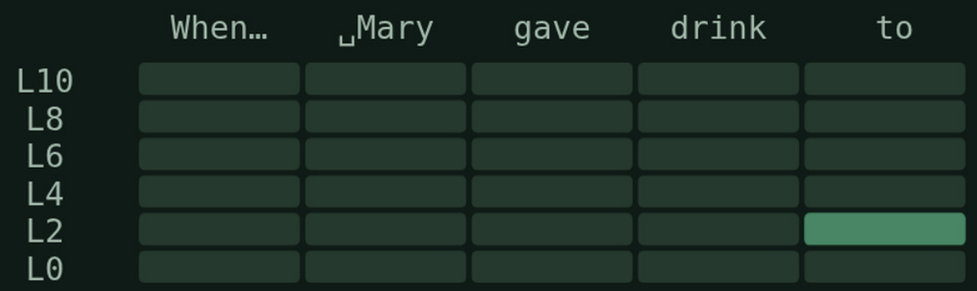
HERRAMIENTA · ACTIVATION PATCHING

Trasplantar una activación para localizar la información



→ Mary

Limpio
…, John gave a drink to



→ John

Corrupto
…, Mary gave a drink to

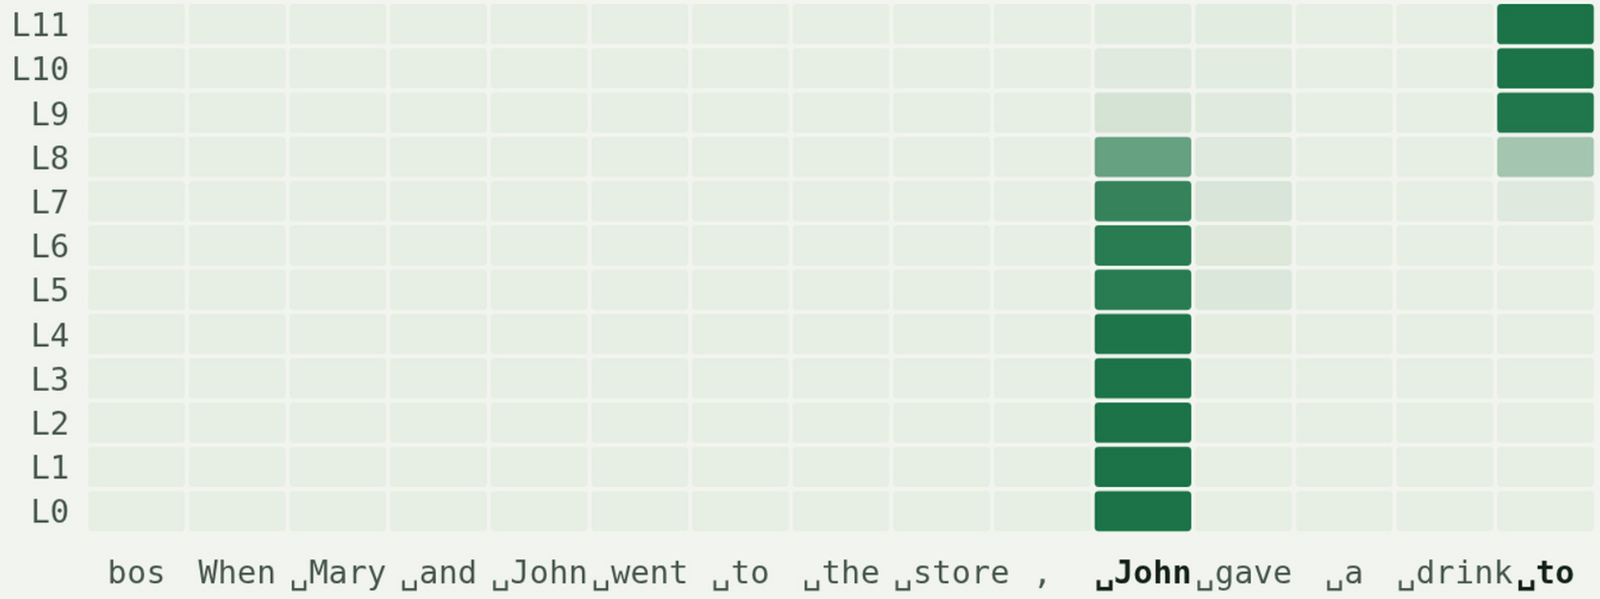
parcheo: L2 en «to»

0.00

S2 = segunda mención del sujeto. Métrica: logit(Mary) − logit(John), normalizada. 0 = corrupto, 1 = limpio. Valores reales

CIRCUITO 2 · INDIRECT OBJECT IDENTIFICATION

La información salta de posición en las capas 8–9

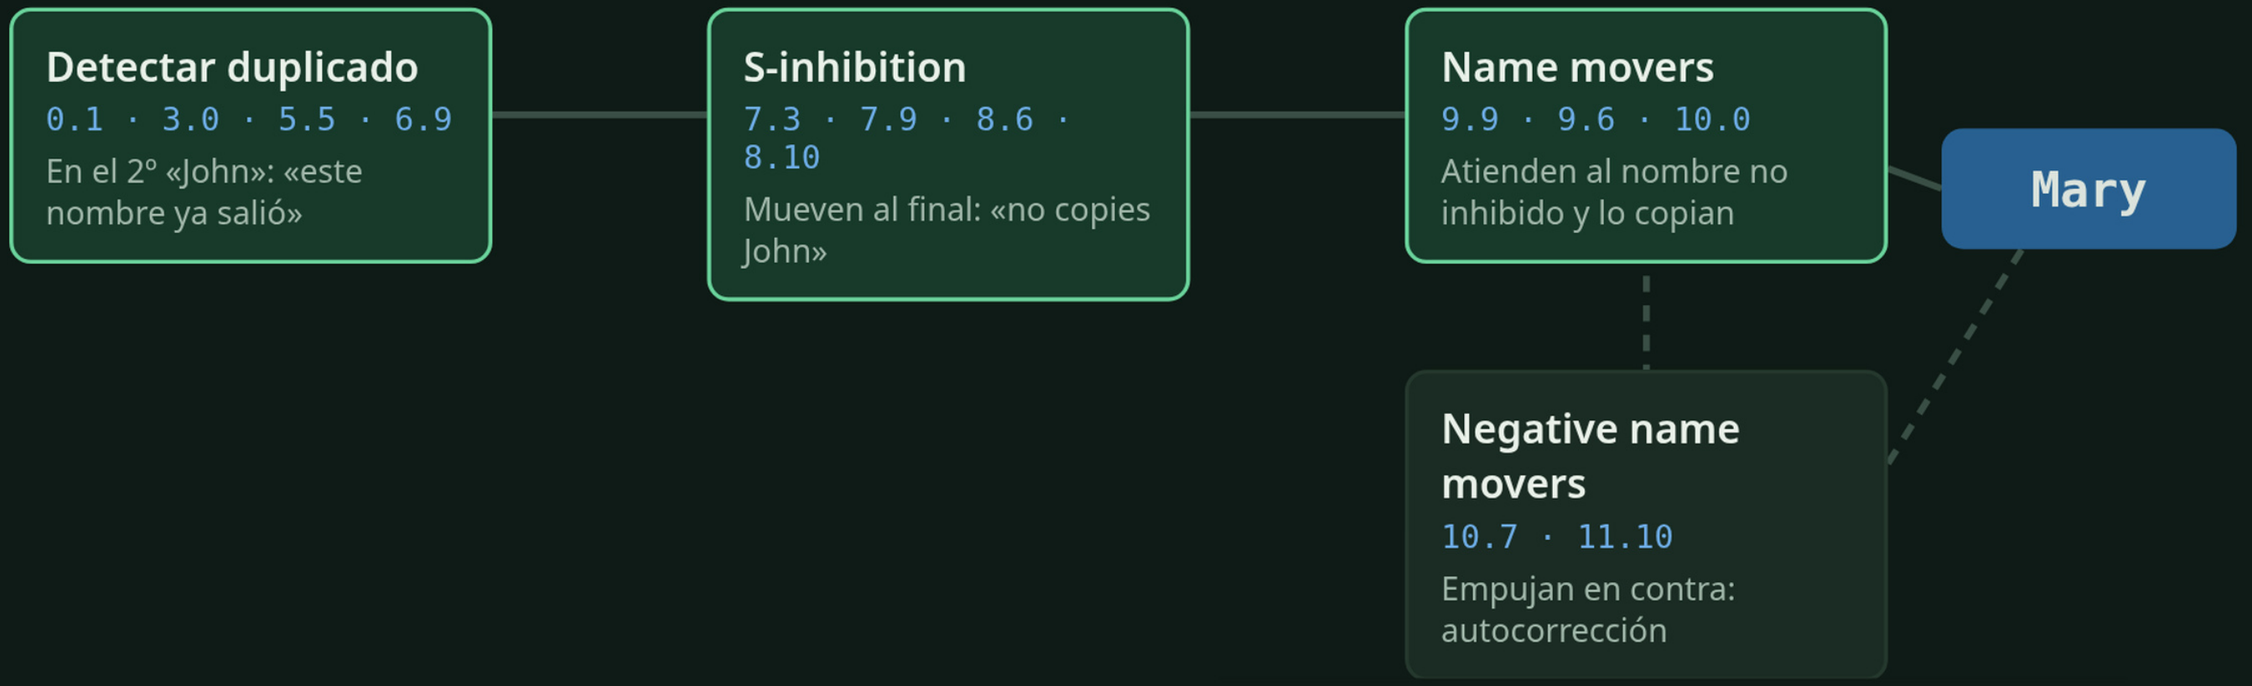


Capas 0–7: la diferencia está en el **segundo nombre**

Parcheo del residual stream (resid_pre) por capa y posición en GPT-2 small. 1 = recupera la respuesta limpia. Datos reales

CIRCUITO 2 · EL ALGORITMO COMPLETO

El circuito IOI: detectar el repetido, inhibirlo, copiar el otro

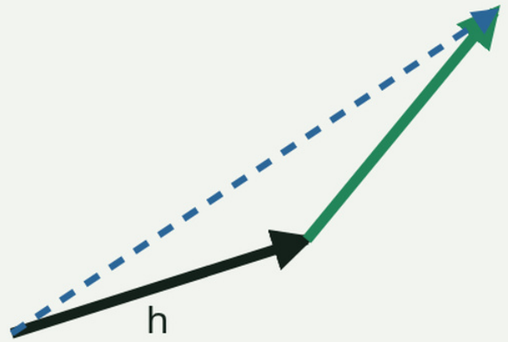


Wang et al. (2022), *Interpretability in the Wild*. Parcheo por cabezas en el notebook: 10.7 (−0,46), 8.10, 9.9, 8.6, 11.10 (−0,18), 7.9

HERRAMIENTA · STEERING

Si un concepto es una dirección, podemos sumarla

```
v = h(“ Love”) − h(“ Hate”)
capa 6 · h ← h + α·v
```



α = 1.5

α = 0 (sin tocar)

I went up to my friend and said, “Hey, you guys are going to the movie theater the next day.”

I went up to my friend and said, “I’d like to talk to you about this.” She really looked at me like I was angry

α = 1,5

I went up to my friend and said this is a big shock! I was excited!!

I went up to my friend and said I had a hot tea and happy! Really excited! I am really happy

GPT-2 small, salidas reales del notebook 2 (temperatura 0,7). Activation addition: Turner et al. (2023)

HACIA DÓNDE VA EL CAMPO · AL NOTEBOOK

Del circuito de juguete a modelos de producción

Sparse autoencoders

Deshacen la superposición: convierten activaciones en miles de features interpretables.

Grafos de atribución

Trazan el circuito de una respuesta concreta en modelos grandes, feature a feature.

Neuronpedia

Explorar features de SAEs de modelos abiertos desde el navegador.

</>

Al notebook de la parte 2

Caché · logit lens · induction heads · ablación · patching IOI · steering. Luego, los retos.

Para seguir: ARENA (arena.education) · TransformerLens · neuronpedia.org · transformer-circuits.pub